Métodos Avanzados de Estimación de Demanda
Modelos de Elección Discreta

Paola Bordón

Facultad de Economía y Negocios
Universidad de Chile

Introducción

- En esta unidad y la siguiente, nos enfocamos en la estimación de demanda para bienes diferenciados.
- Ejemplos: Cerveza (Hausman, Leonard & Zona (1994), Slade (2004), Rojas (2008)), cereales para el desayuno (Nevo (2001)), automóviles (Bresnahan (1987), Goldberg (1995), Berry, Levinsohn & Pakes (1995)), bebidas colas (Gasmi, Laffont, and Vuong (1992)), bancos (Jaumandreu & Lorences (2002)), antibióticos (Chaudhuri, Goldberg & Jia (2004)), papel higiénico (Hausman & Leonard (2002)), carreras universitarias (Bordón, Canales y Mizala (2020)).

Sistema de demanda

J productos diferenciados (por ejemplo distintas cervezas, modelos de automóviles, etc.)

$$Q = D(P, Y),$$

donde $P \in \mathbb{R}_+^J$, $Y \in \mathbb{R}_+$, $Q \in \mathbb{R}_+^J$ y $D : \mathbb{R}_+^{J+1} \mapsto \mathbb{R}^J$.

Demanda en el espacio de los productos

- Críticas
  - Demasiados parámetros: $J \times (J+1)$ parámetros.
  - Heterogeneidad: Modela la demanda agregada asumiendo un consumidor representativo.
  - Introducción de productos nuevos: No permite predecir la demanda para productos nuevos.

Demanda en el espacio de las características

Los productos se modelan como un conjunto de características (observables y no observables).

- Críticas
  - Dificultad para encontrar características relevantes. Incorporación de características no observables en el análisis.
  - Introducción de productos nuevos en nuevas dimensiones
  - Demanda de unidades múltiples y complementaridad
    El consumidor elige entre un conjunto de bienes mutuamente excluyentes.
    No hay margen intensivo (cuánto comprar) y los bienes son sustitutos por definición.

Introducción

- En esta unidad
  - Aprendemos la estimación de demanda en el espacio de la características
  - Presentamos aplicaciones de dicho enfoque

Modelos de estimación de elección discreta

- Diferenciación horizontal pura (Hotelling (1929))

$$U_{ij} = \bar{u} + (y - p_j) - \theta(\delta_j - v_i)^2.$$

- Diferenciación vertical pura (1979, 1982)

$$U_{ij} = \bar{u} - v_i p_j + \delta_j \text{ con } v_i > 0.$$

- Modelo Logit (McFadden (1978, 1981))

$$U_{ij} = x_j'\beta - \alpha p_j + \epsilon_{ij}.$$

- Modelo Nested Logit (McFadden 1978, Berry 1990s)

$$U_{ij} = x_j'\beta - \alpha p_j + \zeta_{ig_j} + (1-\sigma)\epsilon_{ij} = \delta_j + \zeta_{ig_j} + (1-\sigma)\epsilon_{ij},$$

- Berry, Levinsohn, and Pakes (1995) (BLP)

$$U_{ij} = f(v_i, p_j) + \sum_k \sum_r x_{jk} v_{ir} \theta_{kr} + \epsilon_{ij}.$$

donde $f(v_i, p_j) = \log(y_i - p_j)$.

Modelos de elección discreta

- Existen J alternativas en el mercado, indexados por $j = 1, ..., J$.
- El problema del consumidor i es

$$\max_{j,z} U_i(x_j, z) \text{ sujeto a } p_j + p_z z = y_i.$$

donde:

- x_j son las características de la marca j, y el precio es p_j.
- z es la cantidad de la opción alternativa (outside good) y su precio es p_z (generalmente se normaliza p_z a 1).
- La opción alternativa (que se denota como $j = 0$) es la opción de no comprar (lo que implica que se gasta su ingreso disponible en otros bienes).

Modelos de elección discreta

- Substituyendo en la restricción presupuestaria ($z = \frac{y_i - p_j}{p_z}$) se obtiene la función de utilidad indirecta condicional del consumidor para cada marca:

$$U_{ij}^*(x_j, p_j, p_z, y) = U_i(x_j, \frac{y_i - p_j}{p_z})$$

- Si se elige la opción alternativa, entonces:

$$U_{i0}^*(p_z, y) = U_i(0, \frac{y_i - p_j}{p_z})$$

- El consumidor elige la marca que le entrega la mayor utilidad indirecta condicional:

$$\max_j U_{ij}^*(x_j, p_j, p_z, y_i)$$

Demanda agregada

- Defina $A_j(.)$ como la región de las características del consumidor tal que el consumidor prefiere j

$$A_j(x,p) = \{v_i \in \mathbb{R}^L | U_{ij}(.) > U_{ik}(.) \quad \forall k \neq j\}.$$

- Cuota de mercado de j es la densidad de consumidores en la región A_j

$$s_j(x,p;\theta) = \int_{A_j(x,p)} f(v)dv$$

donde θ son los parámetros de la función de utilidad y de la función de distribución de v.

- La demanda de mercado es $q_j = M\, s_j$, donde M es el tamaño del mercado.

Diferenciación horizontal pura (Hotelling)

- Utilidad indirecta condicional

$$U_{ij} = \bar{u} + (y - p_j) - \theta(\delta_j - v_i)^2.$$

- Supongamos una ciudad lineal de tamaño 1 y un duopolio con la firma L ubicada en δ_L y la firma R ubicada en δ_R.
- Los consumidores se distribuyen a lo largo de la ciudad según $f(v_i)$.
- Calculemos $A_L(p, x)$

$$A_L(p, x) = \{v_i | v_i \leq \bar{v}\} \implies D_L(p, x) = \int_{v_i \leq \bar{v}} f(v_i) dv_i = F(\bar{v})$$

donde $\bar{v}$ es el consumidor indiferente.

- El consumidor indiferente es

$$U_{iL} = U_{iR} \iff \bar{v} = \frac{p_R - p_L}{2\theta(\delta_R - \delta_L)} + \frac{\delta_R + \delta_L}{2}.$$

Diferenciación horizontal pura (Hotelling)

- El consumidor indiferente es

$$U_{iL} = U_{iR} \iff \bar{v} = \frac{p_R - p_L}{2\theta(\delta_R - \delta_L)} + \frac{\delta_R + \delta_L}{2}.$$

- Cuotas de mercado

$$s_L(x, p; \theta) = \int_{A_L(x,p)} f(v)dv = \int_{v \leq \bar{v}} f(v)dv = F(\bar{v}),$$
$$s_R(x, p; \theta) = 1 - F(\bar{v}).$$

- Si los consumidores se distribuyen de manera uniforme entonces $F(v) = v$ y

$$s_L(x, p; \theta) = \bar{v} = \frac{p_R - p_L}{2\theta(\delta_R - \delta_L)} + \frac{\delta_R + \delta_L}{2},$$
$$s_R(x, p; \theta) = 1 - \bar{v} = \frac{p_L - p_R}{2\theta(\delta_R - \delta_L)} + (1 - \frac{\delta_R + \delta_L}{2}).$$

Modelo de diferenciación vertical

- Utilidad indirecta condicional

$$U_{ij} = \delta_j - v_i p_j \text{ donde } v_i > 0,$$

δ_j se puede interpretar como la calidad de j y v_i es la utilidad marginal del dinero para el consumidor i.

- Cuotas de mercado para $\delta_2 > \delta_1$

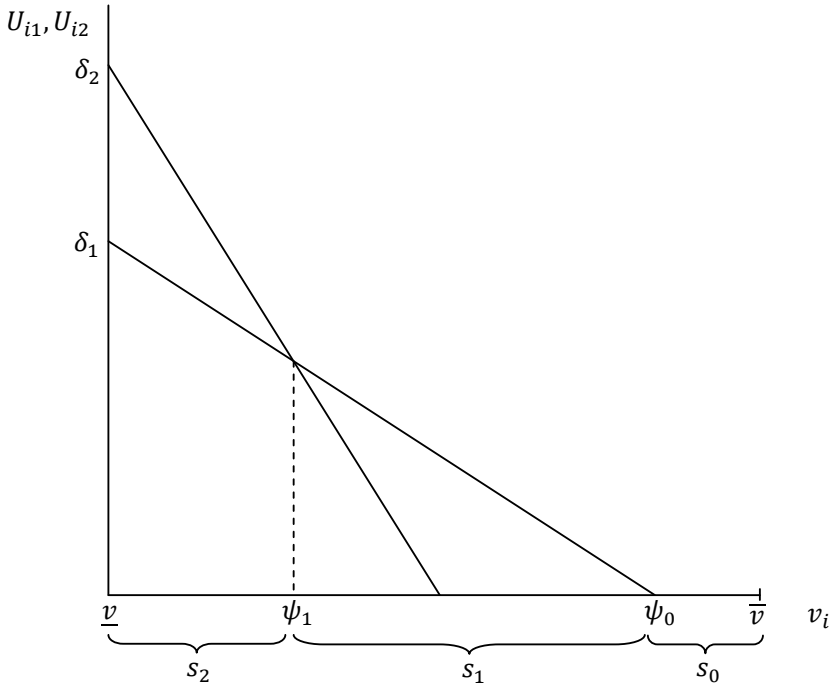

Cuotas de mercado

- Ordenamos los bienes tal que $p_1 < p_2 < ... < p_J$. Es obvio que $\delta_j < \delta_{j+1}$, en caso contrario nadie consume $j+1$.
- Para tener una demanda positiva para cada producto es necesario que $\frac{\delta_j}{p_j} > \frac{\delta_{j+1}}{p_{j+1}}$ para todo j.
- El consumidor i elije NO comprar sí y sólo si

$$\begin{aligned} & 0 > \max_j \delta_j - v_i p_j \\ \iff & 0 > \delta_1 - v_i p_1 \\ \iff & v_i > \frac{\delta_1}{p_1} = \psi_0. \end{aligned}$$

Entonces $s_0(\theta) = \Pr(v_i > \psi_0) = 1 - F(\psi_0)$.

Cuotas de mercado

- El consumidor i elige 1 sí y sólo si

$$\begin{aligned} & \delta_1 - v_i p_1 > \max_j \delta_j - v_i p_j \\ \iff & \delta_1 - v_i p_1 > \delta_2 - v_i p_2 \\ \iff & v_i > \frac{\delta_2 - \delta_1}{p_2 - p_1} = \psi_1. \end{aligned}$$

Entonces $s_1(\theta) = \Pr(\psi_0 > v_i > \psi_1) = F(\psi_0) - F(\psi_1)$.
En general, $s_j(\theta) = \Pr(\psi_{j-1} > v_i > \psi_j) = F(\psi_{j-1}) - F(\psi_j)$ y $s_J(\theta) = \Pr(v_i < \psi_{J-1}) = F(\psi_{J-1})$ donde $\psi_j = \frac{\delta_{j+1} - \delta_j}{p_{j+1} - p_j}$.

Patrones de sustitución

- Elasticidad precio cruzada

  Consumidores solamente sustituyen con los vecinos más cercanos en precio. El resto de las elasticidades cruzadas es cero.

- Elasticidad precio propia

  Elasticidad depende de la densidad de consumidores "indiferentes". Si la distribución de v_i es simétrica entonces las elasticidades son similares para productos con precios altos y bajos.

Modelo Econométrico

- U_{ij}^* usualmente se especifica como la suma de dos partes:

$$U_{ij}^*(x_j, p_j, p_z, y) = V_{ij}(x_j, p_j, p_z, y_i) + \epsilon_{ij}$$

- ϵ_{ij} es conocido para el consumidor, pero no por el econometrista. Representa todo lo que afecta que el consumidor i elija el producto j.
- Dado que los ϵ_{ij} son desconocidos por el econometrista, el producto que elige es aleatorio. Este modelo se conoce como modelo de utilidad aleatoria (McFadden 1978, 1981).
- Los supuestos específicos sobre los ϵ_{ij} determinan las probabilidades de elección del consumidor i, que corresponden a su función de demanda.

Modelo Econométrico

- La probabilidad que el consumidor i elija la marca j es:

$$D_{ij}(p_1...p_j, p_z, y_i) = Prob\{\epsilon_{i0}, ..., \epsilon_{iJ} : U^*_{ij} > U^*_{ik}, \quad \forall k \neq j\}$$

- Si $J = 1$ (el consumidor elige entre comprar el bien 1, o la opción alternativa de no comprar).
- Entonces, el consumidor i elige el bien 1 si:

$$\begin{aligned} & V_{i0} + \epsilon_{i0} \leq V_{i1} + \epsilon_{i1} \\ \iff & V_{i0} - V_{i1} \leq \epsilon_{i1} - \epsilon_{i0} \end{aligned}$$

Modelos simples

- Si asumimos que $\eta_i = \epsilon_{i1} - \epsilon_{i0} \sim N(0,1)$
- Entonces, tenemos el modelo probit.
- En este caso, las probabilidades de elección del consumidor i son:

$$P_{i1} = Pr(\eta_i \geq V_{i0} - V_{i1}) = 1 - \Phi(V_{i0} - V_{i1})$$

- $\Phi(x)$ es la función de distribución acumulada (CDF) de una variable aleatoria que distribuye normal, ie.

$$\Phi(x) = Pr(\eta_i < x)$$

Modelo Logit

- Función de utilidad indirecta condicional

$$U_{ij} = x_j'\beta - \alpha\, p_j + \epsilon_{ij} = \delta_j + \epsilon_{ij},$$

  donde δ_j es la utilidad media y ϵ_{ij} mide las preferencias particulares del consumidor i por el producto j (gustos idiosincráticos).
- Supuestos sobre ϵ_{ij}
  - Tiene una distribución de valor extremo tipo I $F(\epsilon_{ij}) = \exp(-\exp(-\epsilon_{ij}))$
  - Está idéntica e independientemente distribuida ($i.i.d.$) en i y j
- Las probabilidades de elección del consumidor i son:

$$P_{ij} = \frac{\exp(V_{ij})}{\sum_{j'=0,\ldots,J} \exp(V_{ij'})}$$

Cuota de mercado

- Forma analítica para $\Pr(\delta_j + \epsilon_{ij} > \delta_k + \epsilon_{ik}, \forall k | \delta)$

$$s_j(\theta) = \frac{\exp(x_j'\beta - \alpha\, p_j)}{\sum_k \exp(x_k'\beta - \alpha\, p_k)} = \frac{e^{\delta_j}}{\sum_k e^{\delta_k}}$$

- Utilizando la normalización $\delta_0 = 0$

$$s_j(\theta) = \frac{e^{\delta_j}}{1 + \sum_{k=1}^{J} e^{\delta_k}}$$

Elasticidades

- Elasticidad precio propia

$$\frac{\partial s_j}{\partial p_j} = -\alpha\, s_j(1 - s_j),$$

$$\eta_{jj} = \frac{\partial s_j}{\partial p_j}\frac{p_j}{s_j} = -\alpha\,(1 - s_j)p_j.$$

- Elasticidad precio cruzada

$$\frac{\partial s_j}{\partial p_k} = \alpha\, s_j s_k,$$

$$\eta_{jk} = \frac{\partial s_j}{\partial p_k}\frac{p_k}{s_j} = \alpha\, s_k p_k.$$

- Semi-elasticidad: $\frac{\partial \log s_j}{\partial p_k}$ Cambio % en la cuota de mercado cuando el precio aumenta en \$1,000.
- Demostración: Tomar logs en s_j y luego derivar con respecto a p_k.

Patrones de sustitución

Patrones de sustitución

BMW Serie 1 $CLP 34.700.000

Patrones de sustitución

- Elasticidad precio propia

  Productos con cuotas de mercado similares tienen una semi-elasticidad propia similar. Ejemplo: Mercedes Benz Clase A y BYD F3R.

- Elasticidad precio cruzada

  La elasticidad precio cruzada es positiva: todos los productos son sustitutos.

  La semi-elasticidad precio cruzada depende solamente de la cuota de mercado del bien que aumenta el precio. Ejemplo: Si aumenta el precio Mercedes Benz Clase A o el precio de BYD F3R, el efecto sobre la demanda de BMW Serie 1 es el mismo.

Patrones de sustitución

- Los patrones de sustitución son consecuencia del supuesto $i.i.d.$ sobre productos.

  Si ϵ_{ij} vienen de una distribución normal $i.i.d.$ sobre productos, tenemos los mismos problemas.

  Si $\epsilon_i \sim N(0, \Sigma)$ permitimos correlación entre productos pero tenemos $J(J+1)/2$ parámetros adicionales.

Patrones de sustitución

- "Odds ratio" (el ratio de dos probabilidades de elección) entre dos marcas j, j' no depende del número de alternativas disponibles.

$$\frac{P_{ij}}{P_{ij'}} = \frac{\exp(V_{ij})}{\exp(V_{ij'})}$$

independiente de otras alternativas disponibles k, m, l.

Ejemplo: Bus rojo, caminar y metro.

Patrones de sustitución

- Independencia de Alternativas Irrelevantes (IIA)

  Si D_{ij} es la función de demanda, IIA => patrones de sustitución restrictivos:

$$\eta_{a,c} = \eta_{b,c}, \text{para todas las marcas} a, b.$$

  donde

$$\eta_{a,c} = \frac{\partial D_{ia}}{\partial p_c} \frac{p_c}{D_{ia}}$$

  es la elasticidad precio cruzada entre las marcas c y a. Es el cambio porcentual en la demanda del producto a, causado por un cambio en el precio del producto c.

Estimación de Demanda

- Datos

  T mercados con datos de cuotas de mercado s_{jt}, precios p_{jt} y características x_{jt} de los productos.

- Modelo econométrico

  Incorporamos un inobservado en $s_j(\theta)$ que se puede interpretar como un error de muestreo en la estimación de las cuotas de mercado,

$$s_j = \frac{\exp(x_j'\beta - \alpha\, p_j)}{1 + \sum_k \exp(x_k'\beta - \alpha\, p_k)} + \lambda_j.$$

- Estimación

  Mínimos cuadrados no lineales (NLS) o variables instrumentales no lineales (una variable endógena así que necesitamos un instrumento).

Comentarios: Datos de cuotas de mercado

Es usual observar q_j y es necesario hacer un supuesto sobre el tamaño de mercado M para obtener s_j

Ejemplos

- BLP: Demanda de automóviles

  El tamaño de mercado es el número de hogares en EEUU.

- Nevo: Demanda de cereales para el desayuno

  El tamaño de mercado es la población y se supone cierta ración de cereal per capita por día.

Comentarios

- Normalización

  Transformaciones lineales de las utilidades representan las mismas preferencias.
  - Utilidad de la opción de no comprar es cero: $U_{i0} = 0$.
  - Coeficientes de una de las variables es igual a uno. En general, es el coeficiente de una de las variables no observables del consumidor.
- La opción de no comprar es importante para modelar el margen extensivo: comprar o no comprar.
- El margen intensivo está ausente porque la demanda individual es unitaria.

Problemas con los modelos simples

- Overfitting y simultaneidad
  - El modelo es demasiado simple para capturar la realidad, la diferencia entre la cuota de mercado teórica y la observada es el error de muestreo
  - Necesitamos incorporar inobservables de manera más satisfactoria
- Patrones de sustitución son poco realistas

Patrones de sustitución: Modelo Nested Logit

- Los productos se dividen en grupos $g = 1, ..., G$. La utilidad indirecta del consumidor i condicional en comprar el producto j de grupo g_j es

$$U_{ij} = x_j'\beta - \alpha p_j + \zeta_{ig_j} + (1-\sigma)\epsilon_{ij} = \delta_j + \zeta_{ig_j} + (1-\sigma)\epsilon_{ij},$$

  donde $\sigma \in (0,1)$, δ_j es la utilidad media y ϵ_{ij} es la valoración idiosincrática del consumidor i por el producto j (i.i.d. sobre j) y ζ_{ig_j} es la valoración idiosincrática del consumidor i por el grupo g (i.i.d. sobre grupos).
- Nota: La varianza de ζ_{ig_j} es proporcional a σ^2 ($\sigma_\zeta^2 \propto \sigma^2$).
- Sustitución para distintos valores de σ.
- Ejemplo: Segmentos de automóviles como pequeño, compacto, intermedio, familiar, y de lujo.

Modelo Nested Logit

- Supuestos distribucionales
  - ϵ_{ij} se distribuye i.i.d. valor extremo,
  - ζ_{ig_j} se distribuye tal que la distribución marginal de $\zeta_{ig_j} + (1-\sigma)\epsilon_{ij}$ es valor extremo,
  - Cardell (1997) demuestra que para todo σ, existe una única función de distribución para ζ_{ig_j} tal que lo anterior se cumple.

Cuotas de mercado

- La cuota de mercado es

$$
\begin{aligned}
s_j &= s_{j|g_j} s_{g_j} \\
&= \left(\frac{\exp(\frac{\delta_j}{1-\sigma})}{\sum_{k \in g_j} \exp(\frac{\delta_k}{1-\sigma})} \right) \left(\frac{\left[\sum_{k \in g_j} \exp(\frac{\delta_k}{1-\sigma}) \right]^{1-\sigma}}{\sum_{g=1,\ldots,G} \left[\sum_{k \in g_j} \exp(\frac{\delta_k}{1-\sigma}) \right]^{1-\sigma}} \right),
\end{aligned}
$$

donde s_{g_j} es la cuota de mercado del grupo g_j en la demanda total, y $s_{j|g_j}$ es la cuota de mercado del producto j en el grupo g_j.

Matriz de covarianzas de los inobservados

- Definimos $v_{ij} = \zeta_{ig_j} + (1-\sigma)\epsilon_{ij}$ entonces

$$\mathrm{Cov}(v_{ij}, v_{ik}) = \begin{cases} \sigma_\zeta^2 + (1-\sigma)^2\sigma_\epsilon^2 & \text{para } j = k, \\ \sigma_\zeta^2 & \text{para } j \neq k \text{ y} \\ & j, k \text{ en el mismo grupo,} \\ 0 & \text{para } j \neq k \text{ y} \\ & j, k \text{ en distintos grupos.} \end{cases}$$

Elasticidades

- Elasticidad precio propia

$$\frac{\partial s_j}{\partial p_j} = -\alpha s_j \left(\frac{1}{1-\sigma} - \frac{\sigma}{1-\sigma} s_{j|g_j} - s_j \right).$$

  Demostración: Tomar logs y derivar con respecto a δ_k.
- Para $\sigma = 0$ se obtienen las elasticidades del Logit, para $\sigma = 1$ se obtiene una demanda perfectamente elástica.
- La demanda es más elástica cuando la participación en el grupo aumenta (disminuye el número de competidores).

Elasticidades

- Elasticidad precio cruzada

$$\frac{\partial s_j}{\partial p_k} = \alpha s_j \left(\frac{\sigma}{1-\sigma} s_{k|g_j} + s_k \right)$$

para j, k en el mismo grupo

$$\frac{\partial s_j}{\partial p_k} = \alpha s_j s_k$$

para j,k en distintos grupos.

- ¿Cómo cambia la elasticidad con σ (Logit, Bertrand)?

Ejemplo: Model for college-major application (Bordón, Canales & Mizala, EER 2021)

- A continuum of students with a set of high school history, socioeconomic and demographic characteristics (x_i), application score (a_{ij}) and academic interests.
- There are U universities, each with A areas of study (group of majors).
- Let $m \in A$ be a major, and $k \in U$ any university, j (m, k) is a college program.
- Each program differ by admission requirements, fields of study and university quality.
- Students have certain level knowledge in mathematics, language, social science and science, summarized by $s_i = (s_{i1}, s_{i2}, ..., s_{iS})$.

Model for college-major application

- This knowledge generates student's final application score:

$$a_{ij} = \sum_{l=1}^{S} \omega_j s_i \tag{1}$$

where $\omega_j = [\omega_{j1}, ..., \omega_{jS}]$ is the vector weights of program j and $\sum_{l=1}^{S} \omega_{jl} = 1$.

- Students apply to a college-major combination (program) as their first preference in order to maximize their expected utility:

$$U_{ij} = \alpha_j z_s + \beta_k x_{ij} + \epsilon_{ij} \tag{2}$$

Model for college-major application

- In the model we allow for correlation between the choices of areas and universities $\Rightarrow$ **nested logit**.
- z_{ij} represents characteristics of the nest, x_{ij} are the students' characteristics, and ϵ_{ij} follows a generalized extreme value (GEV).
- Let $C_{ij} = 1$ be student i choice of program j, major m and university tier k.
- Let $C_{im} = 1$ be student i choice of major m.
- The probability of student i choosing program j is:

$$P[C_{ij} = 1] = P[C_{ij} = 1|C_{im} = 1]P[C_{ij} = 1] \tag{3}$$

Model for college-major application

$$P\left[C_{ijk}=1|C_{ij}=1\right]=\frac{exp(V_{ijk}/\tau_j)}{\sum_{l\in U_j}exp(V_{jk})/\tau_j)} \tag{4}$$

$$P\left[C_{ij}=1\right]=\frac{exp(\alpha z_{ij}+\tau_j IV_{ij})}{\sum_n exp(\alpha z_{in}+\tau_n IV_{in})} \tag{5}$$

$$IV_{ij}=ln\sum_{j\in B_j}exp(V_{ij}/\tau_j) \tag{6}$$

- IV is also called the log-sum for nest B_j. It represents the expected utility for the choice of alternatives within nest B_j.

Data

Table: Area Applications and Enrollment 2015.

Area	% Applications			% Enrollment		
	Females	Males	Gap	Females	males	Gap
Medicine & Odon.	61%	39%	-22	58%	42%	-16
Health	77%	23%	-54	76%	24%	-52
Sciences	47%	53%	6	46%	54%	8
Civil engineering	24%	76%	52	25%	75%	50
Technology	27%	73%	46	27%	73%	46
Business	49%	51%	2	48%	52%	4
Arts & Music	63%	37%	-26	67%	33%	-34
Social Sc. & HUM	64%	36%	-28	62%	38%	-24
Law	54%	46%	-8	52%	48%	-4
Education	68%	32%	-36	68%	32%	-36

- Gender gaps are generally higher at the application process than in enrollment $\Rightarrow$ selection process seems to decrease the gender gap.
- Important gender gaps in health, engineering, technology and education.

Data

Table: University Applications and Enrollment 2015.

University	% Applications			% Enrollment		
	Females	Males	Gap	Females	males	Gap
Group 1	54%	46%	8	49.5%	50.5%	-1
Group 2	48%	52%	-4	43%	57%	-14
Group 3	56%	44%	12	51%	49%	2
Group 4	57%	43%	14	52%	48%	4

- Selection process increases the gender gap for females in tier 2.

Data

- We use data on students' characteristics and the schools they attended obtained from the Chilean Ministry of Education.
- We follow a cohort of students who graduated from high school in 2014, and applied to enter university in 2015 through the SUA centralized system.
- The data about the characteristics of university candidates, their applications and the final acceptance was provided by DEMRE.
- We defined 10 areas of knowledge: (1) Medicine and Odontology, (2) Health, (3) Sciences, (4) Engineering, (5) Technology, (6) Business, (7) Arts, (8) Social Sciences & Humanities, (9) Law, (10) Education.
- Universities were clustered into four groups, where groups 1-3 have the CRUCH insitutions by selectivity, and group 4 has the private ones.

Data

For the estimation of our nested logit model, we use:

- Individual characteristis (x_{ij}): gender, father's area, mother's area, mix high school class, female high school class, geographic location (region), high school dependence (public, voucher o private), PSU scores (language, math, sciences, social sciences), high school class ranking, high school GPA (biology-chemistry, math-physics, music-arts, humanities) per capita income.
- Program characteristics (z_s): application scores, cutoff scores, average score of programs, vacancies, tuition, student aid, etc.
- Pseudo R^2 of the model for the whole sample, male sample and female sample are: 0.25, 0.24 y 0.23, respectively. The prediction errors are smaller than 1%.

Predicted choice probabilities for an average applicant

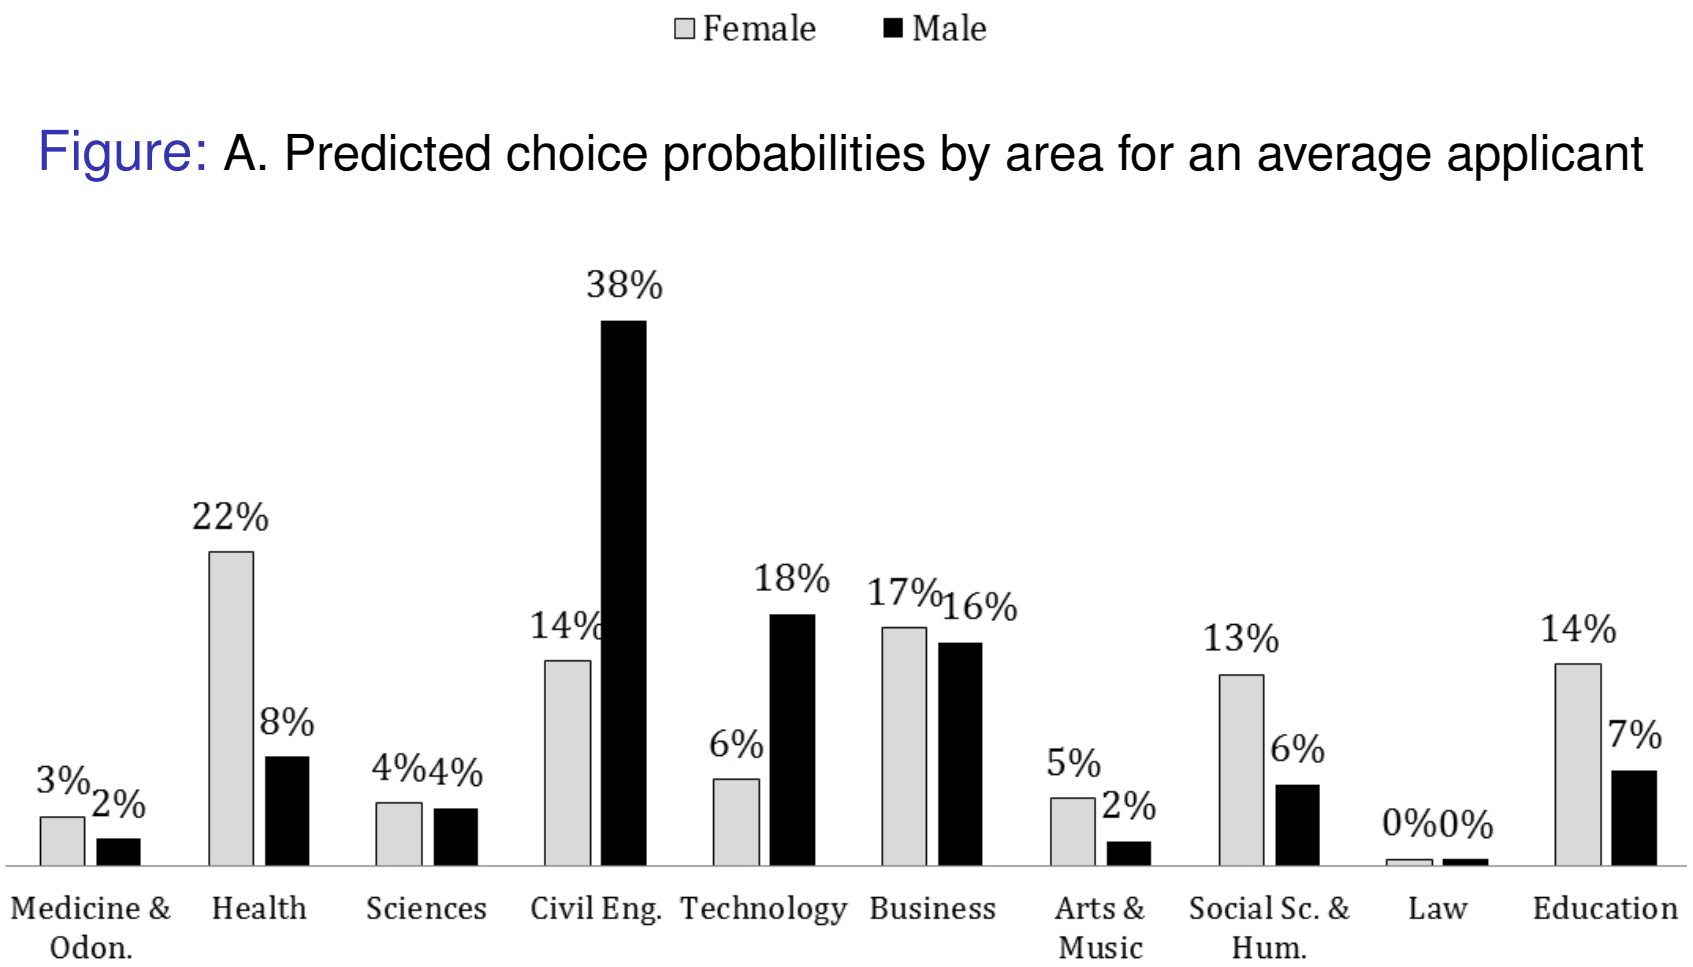

Figure: A. Predicted choice probabilities by area for an average applicant

Predicted choice probabilities for an average applicant

Figure: B. Predicted choice probabilities by group of universities for an average applicant

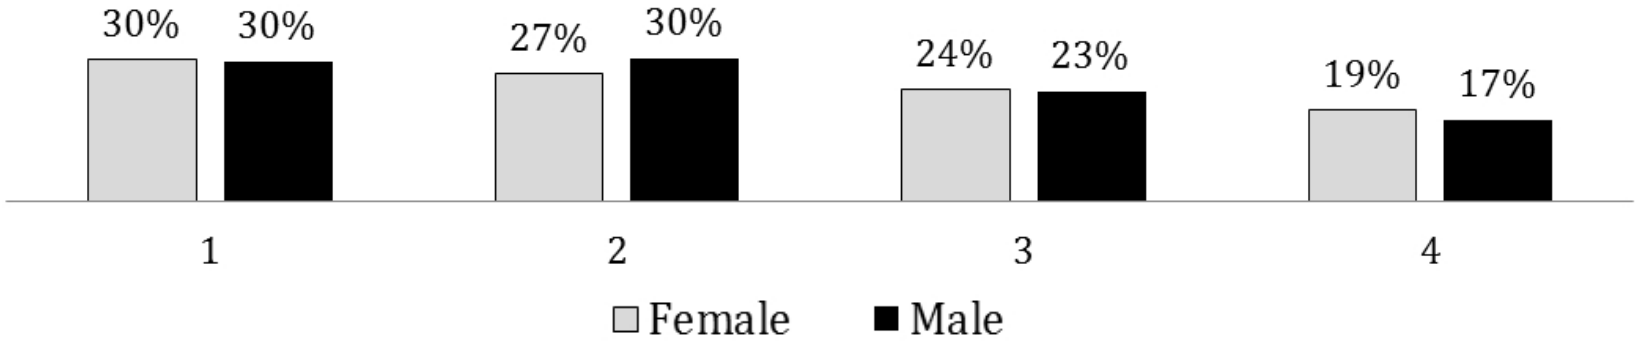

Predicted choice probabilities for an average applicant

Figure: A. Predicted choice probabilities to most selective areas for an average applicant, with different GPA and PSU Scores

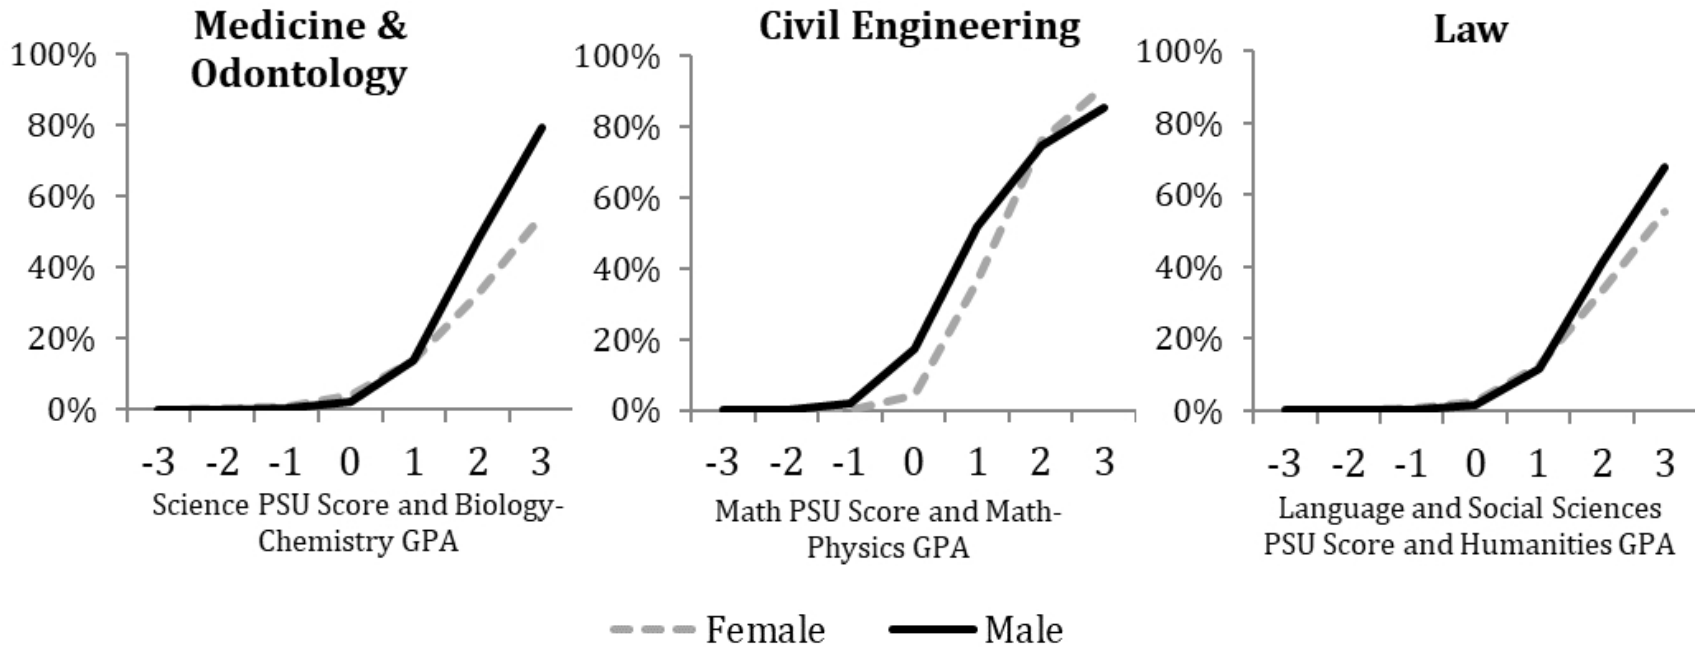

Note: Prediction made using average values for all variables except gender, PSU Score and GPA of the corresponding area.

Predicted choice probabilities for an average applicant

Figure: B. Predicted choice probabilities by group of universities for an average applicant, with different Difference of Score

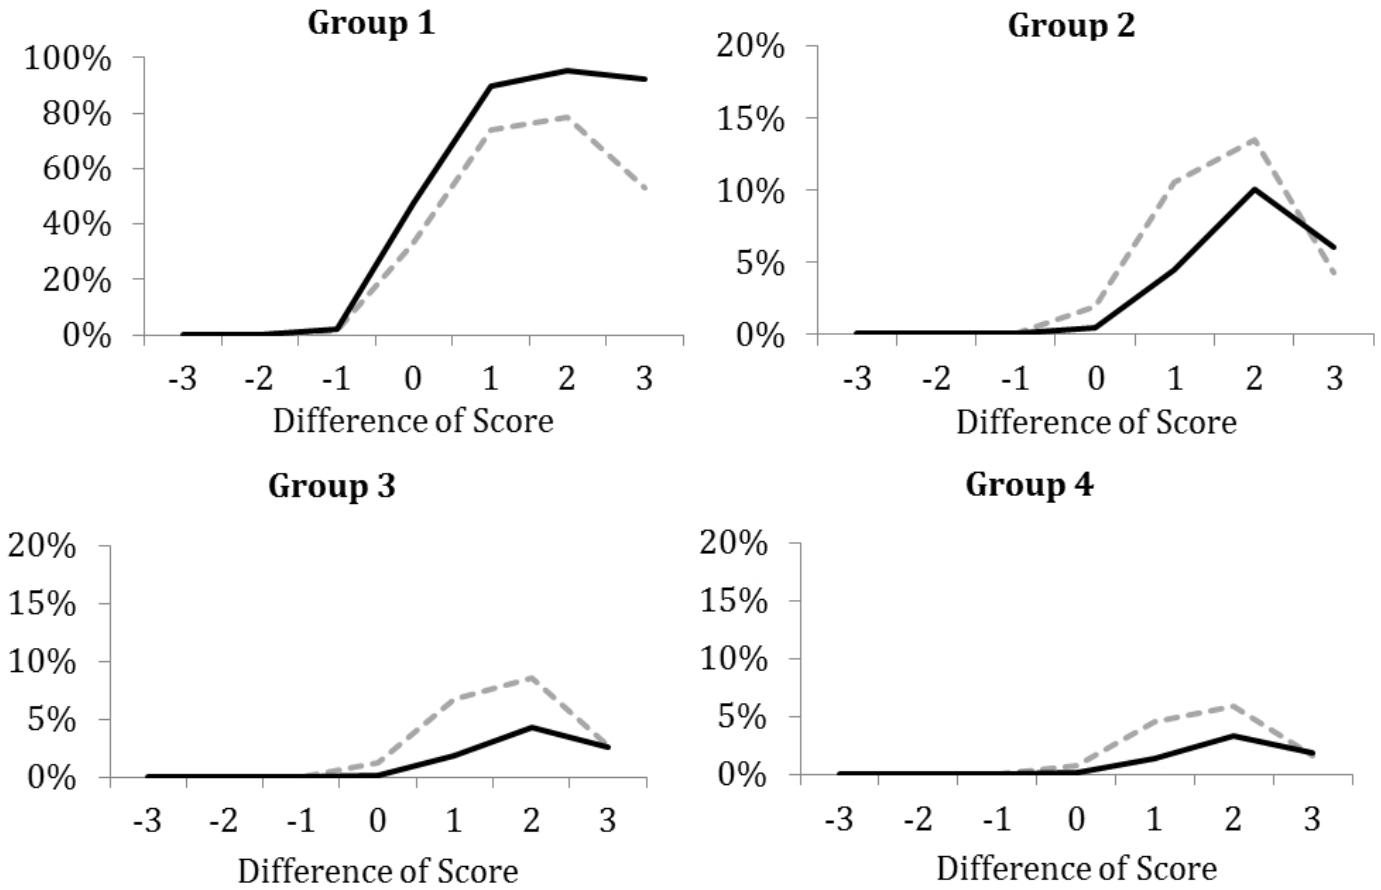

Counterfactuals

Percentages of applicants by area: if females had the same preference parameters as males

Figure: Females' applications by area

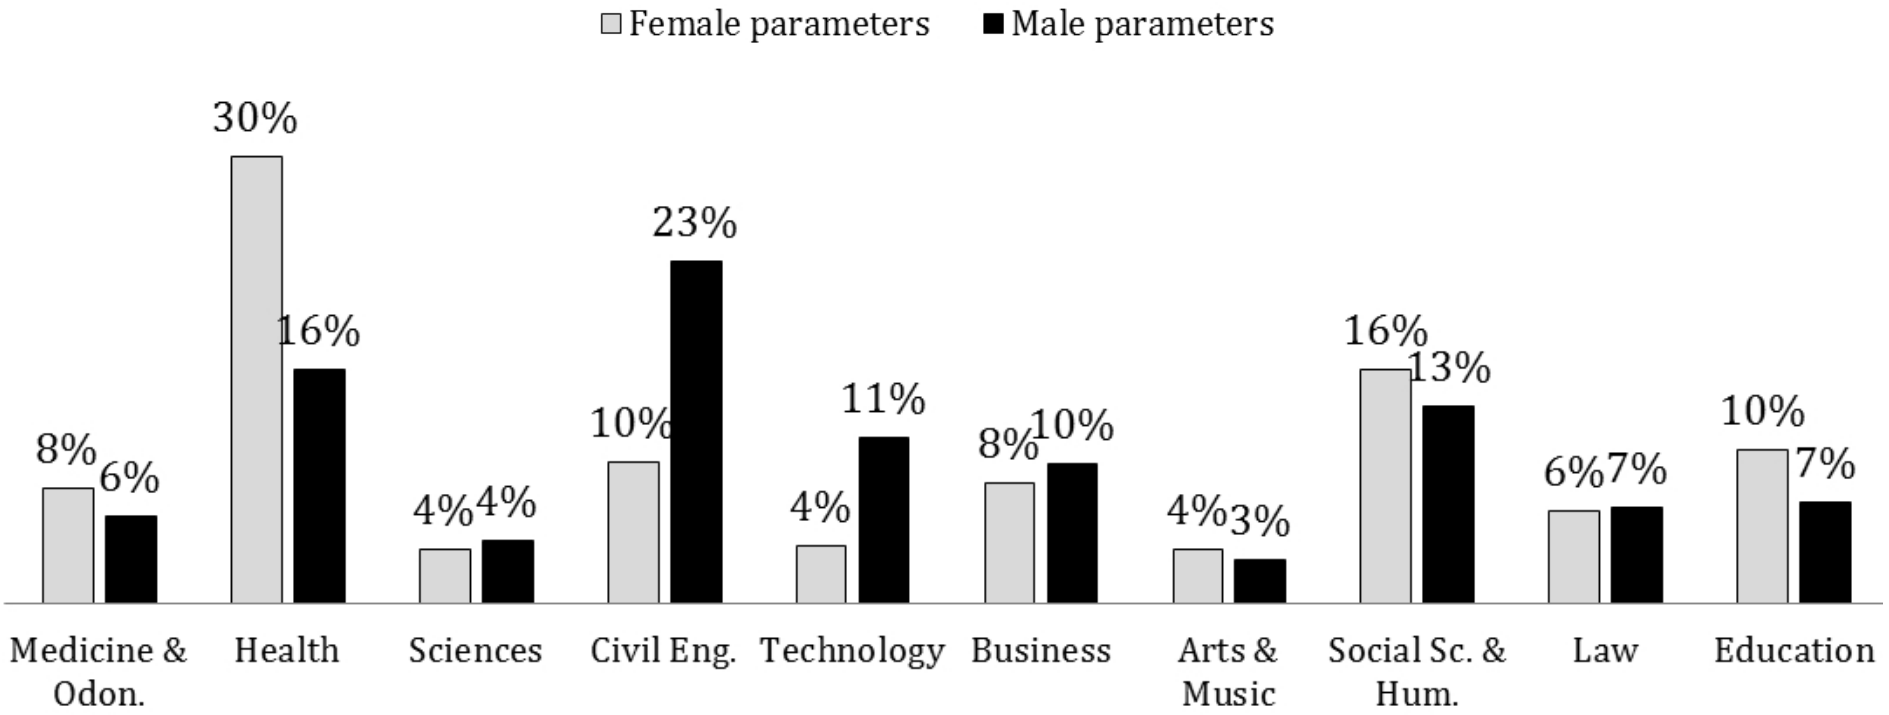

Counterfactuals

Percentages of applicants by area: if males had the same preference parameters as females

Figure: Males' applications by area

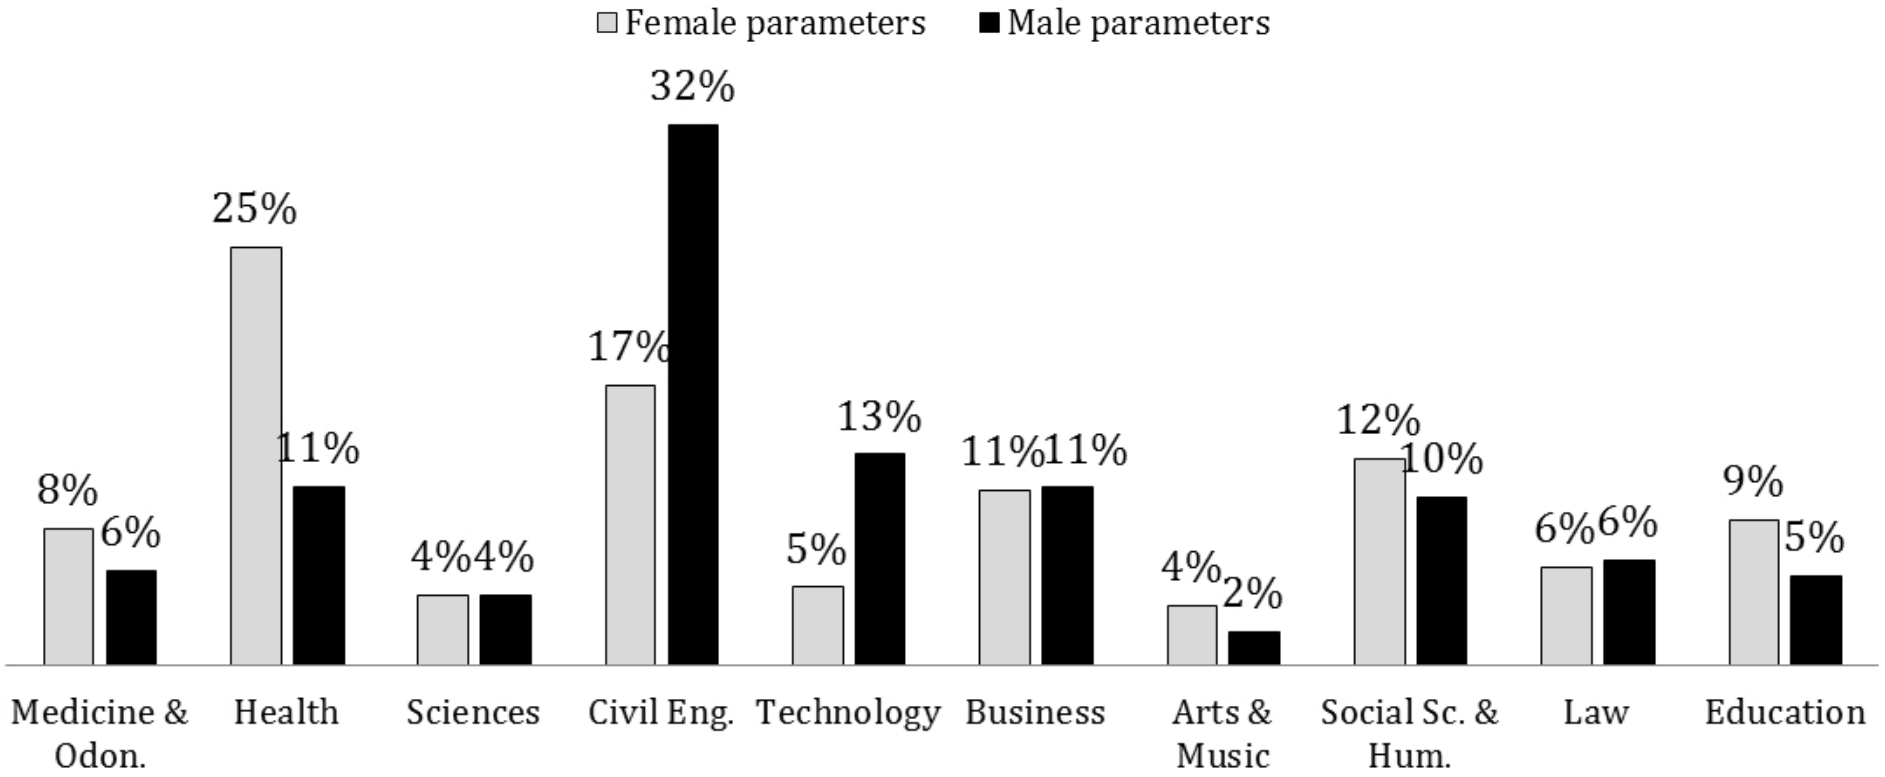

Contrafactuals

Si hombres y mujeres tienen parámetros de preferencias promedio

- En general, el porcentaje de postulantes para cada área seguirá siendo el mismo (con menos del 1% de diferencia).
- Las carreras dominadas por mujeres seguirían estando dominadas por mujeres, pero con una menor proporción de mujeres: 60% vs 77% en salud, 55% vs 61% en medicina y odontología, 59% vs 65% en artes, 60% vs 65% en ciencias sociales y humanidades, y 59% vs 67% en educación.
- Las carreras de ingeniería civil seguirían estando dominadas por hombres, pero con una mayor proporción de mujeres 42% vs 26%.
- Las ciencias y la tecnología cerrarían la brecha de género, 50% vs 47% y 50% vs 28%, respectivamente.